Mineração de Métricas DORA em Repositórios Open-Source que Utilizam GitHub Actions

Pedro Maia Alves[1], **Diogo Brunoro**[1], **Lorran Avelar**[1]

[1]Engenharia de Software
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)

Abstract. *We study DORA proxies in 300 open-source repositories using GitHub Actions, from October 2025 to September 2026. Median release frequency is 0.326 per week and recovery takes 3.20 hours. Delivery frequency correlates with release-based failures but not CI failures. Changing operational definitions reclassifies about 40% of 269 comparable projects. The corrective-release ratio has a median of 37.3%. These results describe GitHub artifacts, not observed production deployments or incidents. Frozen data, code, and executable notebooks support offline reproduction.*

Resumo. *Estudamos proxies DORA em 300 repositórios open-source com GitHub Actions, entre outubro de 2025 e setembro de 2026. A frequência mediana é de 0,326 release por semana e a recuperação leva 3,20 horas. Frequência associa-se às falhas por release, mas não às de CI. Mudar as definições reclassifica cerca de 40% dos 269 projetos comparáveis. A proporção mediana de releases corretivas é 37,3%. Os resultados descrevem artefatos do GitHub, não implantações ou incidentes observados em produção. Dados congelados, código e notebooks executáveis permitem reprodução offline.*

1. Introdução

As métricas DORA descrevem velocidade e estabilidade da entrega de software [Forsgren et al. 2018, DORA sd]. Em projetos open-source, porém, uma release não comprova implantação em produção e uma falha de CI não comprova incidente. O objetivo deste estudo é medir proxies explícitos a partir do GitHub e avaliar quanto os resultados dependem da definição operacional, sem interpretar associação como causa. Investigamos sete questões e um bônus (Tabela 1).

A H2 supõe commits concentrados perto da publicação. A H3 antecipa que CI bloqueie problemas antes de uma entrega. H5 acompanha a ideia de que velocidade e estabilidade não são necessariamente um trade-off [DORA 2026]; H6 considera a capacidade de manutenção das comunidades. H7 antecipa que proxies diferentes possam alterar as categorias. As formulações completas anteriores aos resultados permanecem no histórico do repositório; não foram reescritas para concordar com os achados.

2. Metodologia

População e coleta. O estudo observacional usa a janela oficial inclusiva 01/10/2025–30/09/2026. Os candidatos do snapshot de busca, com 1.000 a 8.000 estrelas, foram embaralhados com semente 42. Exigimos repositório não arquivado, não fork, com Actions, pelo menos 5 releases principais e 50 runs válidos. A amostra congelada tem 300 projetos; a Tabela 2 distingue os candidatos retornados dos avaliados.

Tabela 1. Questões e expectativas registradas antes da análise (H1–H7).

RQ	Questão	Hipótese informal
01	Qual a frequência das entregas?	H1: mediana menor que uma release/semana, com cauda longa.
02	Qual o tempo entre commit e entrega?	H2: lead time por release bem maior que por commit.
03	Qual a taxa de falha?	H3: CFR de CI maior que CFR por releases corretivas.
04	Qual o tempo de recuperação?	H4: poucas horas, cauda pesada e censura não desprezível.
05	Frequência associa-se a falhas?	H5: associação fraca e negativa.
06	Quais características se associam às métricas?	H6: tipo e contribuidores mais associados que linguagem.
07	A classificação depende da definição?	H7: concordância moderada/alta, com trocas próximas aos cortes.
08	Qual a proporção de releases corretivas?	Bônus descritivo: rework rate, sem nova hipótese prévia.

Tabela 2. Funil: snapshot de busca reutilizado, sem alegar consultas adicionais.

Etapa	Repositórios restantes
Candidatos retornados	53.143
Candidatos efetivamente avaliados	2.644
Com GitHub Actions	1.495
Com cinco releases principais	413
Com cinquenta runs válidos / amostra congelada	300

O pipeline Python usa `requests` na API REST para releases, comparações, commits, contribuidores e runs; tags também podem ser consultadas em lotes por GraphQL. Paginação inclui comparações com mais de 250 commits. Runs são do evento push no default branch. Consultas mensais saturadas são subdivididas; dias ainda saturados impedem o congelamento. Cache e checkpoints permitem retomada, com espera pelos cabeçalhos de rate limit e backoff em falhas transitórias. A coleta terminou em 15/10/2026, 05:15 UTC. A instrumentação parcial registrou 25.634 respostas HTTP e três segundos de espera solicitada, sem cobrir o início nem os acertos de cache. Não usamos esses registros para estimar a duração integral da coleta.

Definições. Frequência é o número de releases principais dividido pelas semanas da janela inclusiva. Drafts e pré-releases ficam fora da referência; as variantes incluem pré-releases ou usam tags datadas pela autoria do commit apontado, não pela criação da tag. Lead time usa `commit.author.date`, em horas: (a) mediana entre releases do tempo até o commit mais antigo; (b) mediana de todos os pares release/commit. Comparações 404, datas inválidas e releases sem commits não viram tempos zero. São nove comparações 404 e 561 pares com datas inválidas.

CFR (a) é falhas/(falhas+sucessos) de CI: sucesso = `success`; falhas = `failure`, `timed_out`, `startup_failure`; outros estados são ignorados e contados. No CFR (b), uma release falha se uma corretiva posterior sai em até sete dias, inclusive. As datas 24–30/09/2026 ficam fora do denominador (274 releases censuradas), mas suas corretivas podem identificar falhas anteriores. Lacunas textuais não positivas pela v3 tornam o CFR (b) indisponível em 11 projetos.

Recuperação é medida por workflow: do início da primeira falha depois de sucesso até o término do sucesso seguinte. Falhas consecutivas formam um episódio; sem sucesso posterior há censura. Falhas iniciais sem sucesso anterior não iniciam episódio observável. Dos 7.861 episódios, 90 são censurados; 22 projetos não têm episódio observável e ficam sem tempo de recuperação, não com recuperação zero.

Validação manual. Sorteamos 60 projetos e cinco releases por projeto, com semente 42 e ordenações estáveis, para três avaliações declaradas humanas e independentes, sem previsões da heurística. Julgaram tipo, se releases são entregas reais e objetivo corretivo. O consenso é unanimidade/maioria; não houve empate 1–1–1. Kappa de Fleiss foi 0,97, 1,00 e 0,96 nessas dimensões. Os outros 240 tipos foram revisados individualmente, 80 por integrante, após sugestões automáticas, com evidências e proveniência separadas do consenso triplo.

A heurística v3 aceita tags SemVer com escopo e analisa títulos dos commits. Ignora manutenção, documentação, CI e dependências; identifica correções e funcionalidades, contando cada commit no máximo uma vez. Havendo funcionalidades, exige ao menos três commits corretivos e razão correções/funcionalidades de pelo menos 2,5. Sem funcionalidades, basta um corretivo elegível. Com texto ligado, patch sozinho não basta. Contra o consenso, obteve precisão 0,708, recall 0,782 e F1 0,743 (68 VP, 28 FP, 19 FN, 185 VN). Refinamento e avaliação usaram a mesma amostra: não é uma estimativa de generalização para dados não vistos.

Análise e sensibilidade. Cada projeto pesa igualmente; reportamos mediana e quartis lineares. H2/H3 usam Wilcoxon bilateral pareado, efeito rank-biserial e Holm em dois testes. RQ05 usa Spearman, IC95% BCa pareado e permutação bilateral (9.999 reamostragens, semente 42), com Holm nos dois proxies [SciPy Community 2026b, SciPy Community 2026a]. RQ06 usa tipo, contribuidores em quartis e linguagem (frequência menor que dez agrupada em Outras). Grupos são definidos nos 300 antes das exclusões; mínimo cinco por grupo. Kruskal–Wallis usa $\varepsilon^2 = H/(n-1)$; havendo dois grupos, Mann–Whitney usa $\delta = 2U/(n_1 n_2) - 1$. Holm corrige juntos os 18 testes.

Na RQ07, usamos os cortes fixos da disciplina, não novos benchmarks DORA: frequência ≥ 7, ≥ 1, $\geq 7/30$ por semana; lead time < 24, < 168, < 720 h; CFR $\leq 0,15$, $\leq 0,30$, $\leq 0,45$; recuperação < 1, < 24, < 168 h (Elite, High, Medium; demais Low). Categoria geral é a mediana das quatro notas (Low=1 a Elite=4), arredondada para baixo, exigindo todas as métricas. As combinações da Tabela 3 foram adotadas nesta integração, conforme permitido no planejamento, sem alterar rótulos ou a heurística.

Tabela 3. Combinações da RQ07. Só a fonte da frequência muda com pré-releases/tags; lead times e CFR (b) continuam baseados nas releases principais congeladas.

	Frequência	Lead time	CFR	Recuperação
C1	Releases principais	(a)	CI (a)	CI
C2	Principais + pré-releases	(b)	Releases (b)	CI
C3	Tags	(b)	Releases (b)	CI

Calculamos proporção de trocas e kappa de Cohen com pesos lineares na ordem das categorias [scikit-learn developers 2026]. Ausência não é categoria: informamos n por par, ganhos/perdas de classificação e interseção tripla. A robustez exploratória re-

pete as correlações para as três frequências (Holm em seis testes) e acrescenta as duas frequências à RQ06 (24 testes únicos, sem duplicar métricas invariantes). Essas famílias ampliadas não substituem os testes originais de H5/H6.

Reprodução. Python 3.12.14, Pandas/NumPy, SciPy, Statsmodels, scikit-learn e Matplotlib executam offline sobre 311 fontes congeladas em ZIP. Os manifestos registram versões exatas, parâmetros e hashes SHA-256 das entradas, código e saídas. Os módulos `analises.sprint3_a`, `analises.sprint3_b` e `analises.sprint3_c`, executados com `python -m` a partir de `Lab03/`, geram as análises; os seis notebooks conferem os CSVs em kernels novos. Testes usam fixtures e resultados conhecidos, sem API real. O dataset da S02 não é alterado pelas análises.

3. Resultados

3.1. RQ01–RQ04: métricas e referência C1

A Tabela 4 reúne as variantes. O CFR (b) tem 289 observações e a recuperação, 278; as ausências não são imputadas.

Tabela 4. Medianas e quartis; peso igual por projeto, exceto episódios na última linha.

RQ	Métrica	Unidade	n	Mediana	Q1–Q3	IQR
RQ01	Frequência: releases	por semana	300	0,326	0,153–0,825	0,671
RQ01	Frequência: com pré-releases	por semana	300	0,345	0,173–0,863	0,690
RQ01	Frequência: tags	por semana	300	0,403	0,192–1,016	0,825
RQ02	Lead time (a): por release	horas	300	196,7	47,26–715,6	668,3
RQ02	Lead time (b): por commit	horas	300	178,3	43,10–475,4	432,3
RQ03	CFR (a): runs de CI	proporção	300	0,055	0,024–0,129	0,105
RQ03	CFR (b): releases	proporção	289	0,175	0,000–0,429	0,429
RQ04	Recuperação: mediana por projeto	horas	278	3,20	0,60–18,37	17,77
RQ04	Recuperação: episódios concluídos	horas	7.771	3,57	0,88–20,28	19,40

RQ01. A frequência mediana de 0,326 release/semana equivale a aproximadamente uma a cada três semanas. Só 56 projetos (18,7%) chegam a uma por semana e 3 a sete. Incluir pré-releases eleva a mediana a 0,345; tags, a 0,403. A cauda à direita e a baixa mediana sustentam H1.

RQ02. Lead time (a) é 196,7 h e (b), 178,3 h. (a) supera (b) em 191/300 projetos (Wilcoxon/Holm: $p = 1{,}12 \times 10^{-6}$, $r = 0,325$), com razão mediana 1,49. H2 é parcial: a diferença é menor que a esperada. Dentro dos projetos, releases com mais commits têm o primeiro commit mais antigo (Spearman mediano 0,75 nos 296 projetos avaliáveis), aproximando as medidas. (b) pondera pelo número de commits; (a), igualmente por release.

RQ03. O CFR (b) mediano de 0,175 supera o CFR (a), 0,055, e é maior em 186/289 pares (p Holm = $8{,}13 \times 10^{-16}$; r =-0,554). H3 não é sustentada: ocorre o inverso. Falhas de CI e corretivas observam problemas diferentes; nenhuma mede diretamente incidentes em produção. Em 74 projetos, CFR (b) é legitimamente zero.

RQ04. A recuperação mediana por projeto é 3,20 h. Nos 7.771 episódios concluídos, P90 é 73,37 h; a cauda é longa, mas só 1,1% dos episódios são censurados. Se todos os censurados durassem mais que os concluídos, a mediana por projeto passaria para 3,33 h. H4 é parcial: poucas horas e cauda pesada, mas pouca censura.

Em C1, a classificação geral é Elite em 17 projetos, High em 122, Medium em 110 e Low em 29; 22 ficam sem categoria. A frequência é a dimensão mais fraca: 40,7% e 40,7% ficam em Medium e Low. Já o CFR de CI classifica 78,3% como Elite.

3.2. RQ05: frequência e taxa de falha

O rho de CI é próximo de zero e seu IC inclui zero; em entregas, a associação é positiva, não a fraca associação negativa prevista por H5 (Tabela 5). Não rejeitar a hipótese nula em CI não comprova independência. A influência leave-one-out não muda o sinal de nenhum rho: as maiores variações são 0,0093 (CI) e 0,0076 (entregas). Esse diagnóstico não elimina confundimento.

Tabela 5. RQ05: Spearman, IC95% BCa e permutação com Holm (família de dois).

Proxy	n	ρ [IC 95%]	p Spearman	p perm./Holm
CFR (a)	300	0,015 [-0,095; 0,125]	0,7993	0,8096
CFR (b)	289	0,660 [0,585; 0,724]	$1,48 \times 10^{-37}$	0,0004

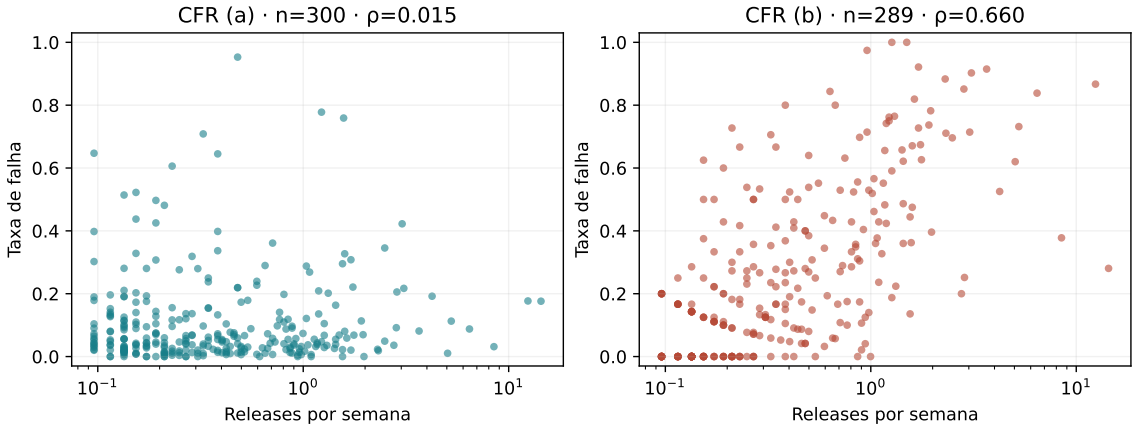


Figura 1. RQ05: os mesmos projetos, mas proxies distintos de falha. Só a frequência usa escala logarítmica; taxas zero são preservadas.

3.3. RQ06: fatores associados

Seis dos 18 testes permanecem significativos após Holm (Tabela 6). Contribuidores e linguagem associam-se aos lead times; contribuidores também à recuperação, e tipo apenas à recuperação. Não há evidência após Holm para frequência ou CFR em nenhum fator. H6 é parcial: linguagem não é menos relevante que tipo, e associações não demonstram capacidade causal das comunidades. Testes globais não identificam pares específicos; não executamos post-hoc. Os 18 resultados e os tamanhos de cada grupo permanecem nos CSVs suplementares.

3.4. RQ07: sensibilidade das classificações

C1 é reproduzida exatamente antes das comparações. C1 possui 278 classificações; C2/C3, 269. Nove projetos perdem classificação porque trocar CI por CFR (b) introduz uma métrica ausente; isso não é contado como troca de categoria. A Tabela 7 separa populações por par e comum às três (coincidentes nesta amostra). As matrizes da Figura 2 mostram inclusive os zeros e a direção das trocas.

Tabela 6. RQ06: testes que sobrevivem a Holm; todos são Kruskal–Wallis nesta amostra.

Fator	Métrica	n	p Holm	ε^2 / δ
Tipo do projeto	Recuperação	278	0,0347	0,051
Contribuidores (quartis)	Lead time (a)	300	$8,10 \times 10^{-7}$	0,124
Contribuidores (quartis)	Lead time (b)	300	$6,11 \times 10^{-9}$	0,157
Contribuidores (quartis)	Recuperação	278	0,0092	0,062
Linguagem	Lead time (a)	300	0,0002	0,124
Linguagem	Lead time (b)	300	0,0199	0,084

Tabela 7. RQ07: mudanças de categoria e Cohen linear; sem par = excluídos do cálculo.

Par	População	n	Mudaram	%	κ_w	Sem par
C1–C2	Por par	269	106	39,4	0,455	31
C1–C2	Comum às três	269	106	39,4	0,455	31
C1–C3	Por par	269	108	40,1	0,437	31
C1–C3	Comum às três	269	108	40,1	0,437	31
C2–C3	Por par	269	12	4,5	0,931	31
C2–C3	Comum às três	269	12	4,5	0,931	31

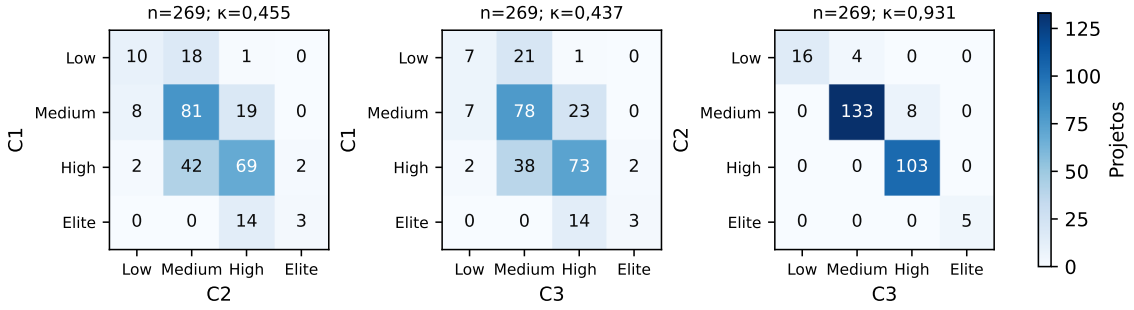


Figura 2. Categorias gerais, de Low a Elite. Linha: combinação de origem; coluna: destino. Ausências não entram como categoria.

C1–C2 muda 39,4% dos 269 projetos ($\kappa_w = 0,455$); C1–C3, 40,1% ($\kappa_w = 0,437$). C2–C3 muda só 4,5% ($\kappa_w = 0,931$). H7 é parcialmente sustentada: há concordância moderada a alta, mas trocar conjuntamente lead time e CFR reclassifica cerca de quatro em dez projetos. Essas comparações não isolam o efeito de cada mudança.

As conclusões de RQ01–RQ04 mantêm baixa frequência, lead time de vários dias, diferença entre proxies de falha e recuperação tipicamente curta. A recuperação é invariável por construção nas três combinações, não uma nova confirmação empírica. Na RQ05, trocar a fonte da frequência mantém CI sem evidência após Holm e CFR (b) positivo (ρ entre 0,599 e 0,660; p ajustado 0,0012 na família de seis). Na RQ06 ampliada, nenhuma frequência se associa aos fatores após Holm. As associações de contribuidores/linguagem aos lead times e de contribuidores à recuperação persistem; tipo–recuperação deixa de atingir 5% na família de 24. Isso mostra sensibilidade à multiplicidade, sem apagar o teste original de H6.

3.5. RQ08 bônus: rework rate

Escolhemos uma opção: releases principais corretivas divididas pelo total de principais na janela, usando a v3 e a disponibilidade da RQ03 (b). Não censuramos os últimos sete dias, pois não é preciso observar uma release futura para contar a própria corretiva. A mediana é 37,3%, com 289 projetos e 11 ausentes. Nos mesmos projetos, rework supera CFR (b) em 178 casos; diferença pareada mediana de 11,1 pontos percentuais. Não é a mesma medida: CFR conta as releases anteriores seguidas de corretiva em sete dias. Uma corretiva pode marcar várias anteriores como falhas, mas é contada uma vez em rework. Quatro releases em dias consecutivos, apenas a última corretiva, dão 25% de rework e 75% de CFR, fora da fronteira censurada.

A regra herdada pode produzir negativos sem antecessora/commits. A sensibilidade de evidência completa torna desconhecidas 1.899 de 11.453 releases e deixa 201 projetos avaliáveis, com mediana 40,0%. Tratar todas as desconhecidas como negativas/positivas delimita a proporção agregada por release entre 32,07% e 48,65%. Não são intervalos de confiança nem medianas por projeto, e não incluem erros da heurística. O DORA observa implantações não planejadas por incidentes em produção [DORA 2026]; nosso proxy de releases corretivas não comprova essas condições.

4. Discussão e ameaças à validade

Síntese das hipóteses. H1 é sustentada; H2, H4, H6 e H7, parcialmente; H3 e H5 não são sustentadas. A frequência típica é baixa, enquanto recuperação de CI é rápida. Comunidades maiores associam-se a lead times maiores, contrariando uma interpretação simplista de que mais contribuidores garantem velocidade. A divergência mais importante é de construto: trocar falhas de CI por releases corretivas altera tanto a relação com frequência quanto a classificação geral. É plausível que publicar frequentemente aumente a oportunidade de observar outra release em sete dias, mas o estudo não identifica esse mecanismo causalmente.

Construto. Releases e tags não equivalem a deploys; CI não é produção. Tags usam autoria do commit, suscetível a rebase/squash, e podem não representar a criação da versão. O CFR (b) depende de heurística imperfeita, de versões paralelas e da janela de sete dias. Rework também não demonstra retrabalho causado por incidente. Faixas fixas

da disciplina não são benchmarks universais atuais. O arredondamento da mediana afeta 132 classificações de C1: notas centrais diferentes deixam projetos próximos a um corte.

Interna e de conclusão. Idade, domínio, popularidade, governança e tamanho dos projetos não foram controlados causalmente. Compartilhar ecossistema pode introduzir dependência entre repositórios. Subgrupos desiguais (tipo outro tem só seis recuperações disponíveis), ausências informativas e muitos testes limitam inferências. Reportamos n, efeitos, intervalos e Holm, preservando testes não significativos e resultados não estimáveis. As famílias exploratórias maiores alteram a significância de tipo–recuperação, embora os dados não tenham mudado.

Validação e validade externa. Três avaliações humanas foram declaradas pelos integrantes; hashes verificam integridade, não independência cognitiva. Os 240 tipos complementares tiveram uma avaliação por projeto após sugestões automáticas, com possível ancoragem. Refinar e avaliar a v3 na mesma amostra pode superestimar F1; não houve teste separado de generalização. Seleção por popularidade, uso de Actions e mínimo de releases/runs exclui projetos menores, inativos, corporativos e outros sistemas de CI. A janela de um ano não permite extrapolar para toda a história dos projetos. Reprodutibilidade offline não elimina essas limitações e não equivale à replicação independente por outro grupo.

5. Conclusão e material de reprodução

Os proxies permitem estudar a cadência e a recuperação de CI, mas conclusões sobre estabilidade dependem da definição. As categorias mudam em cerca de 40% dos pares C1–C2/C3, apesar de os dados serem os mesmos. Recomendamos reportar variantes, ausências e denominadores, evitando rótulos de desempenho sem explicitar os proxies. O bônus complementa CFR (b) ao contar corretivas, não as versões que as precedem.

Código, dataset congelado, fontes, testes, notebooks, dicionários e comandos de reprodução estão no repositório do grupo:

`https://github.com/PedroMaiaAlves/lab-experimentacao-software`

O índice de projetos associado ao repositório está em `https://github.com/PedroMaiaAlves/lab-experimentacao-software/projects`. A execução local não comprova publicação na main, atualização do quadro ou replicação cruzada. Sem repositório sorteado, dataset comparável e registros de execução externa, não declaramos essa etapa concluída nem inventamos Issues ou respostas de outros grupos.

Referências

DORA (2026). DORA's software delivery performance metrics. `https://dora.dev/guides/dora-metrics/`. Acesso em: 7 out. 2026.

DORA (s.d.). Accelerate state of DevOps reports. `https://dora.dev/research/`. Acesso em: out. 2026.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

scikit-learn developers (2026). cohen_kappa_score. `https://scikit-learn.org/stable/modules/generated/sklearn.metrics.cohen_kappa_score.html`. Acesso em: 21 out. 2026.

SciPy Community (2026a). scipy.stats.bootstrap. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.bootstrap.html. Acesso em 18 de outubro de 2026.

SciPy Community (2026b). scipy.stats.spearmanr. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html. Acesso em 18 de outubro de 2026.