Mineração de Métricas DORA em Repositórios Open-Source que Utilizam GitHub Actions

Pedro Maia Alves[1], **Diogo Brunoro**[1], **Lorran Avelar**[1]

[1]Engenharia de Software
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)

Abstract. *This study investigates delivery performance in popular open-source repositories that use GitHub Actions. Releases, commits, and workflow runs are adopted as explicit operational proxies for the four DORA metrics. The study also evaluates how alternative definitions affect repository classification. This document presents the research questions, hypotheses, collection protocol, and the frozen sample of 300 repositories. Three declared independent human assessments cover 60 projects and 300 releases. The revised heuristic meets the F1 threshold of 0.70 on that sample. Project types cover all 300 repositories: the remaining 240 were individually reviewed after automatic pre-classification. RQ05 and RQ06 are analyzed with rank-based tests, multiplicity correction, bootstrap confidence intervals, permutation tests, and influence analysis.*

Resumo. *Este estudo investiga o desempenho de entrega em repositórios open-source populares que utilizam GitHub Actions. Releases, commits e execuções de workflows são adotados como proxies operacionais explícitos para as quatro métricas DORA. O estudo também avalia como definições alternativas afetam a classificação dos repositórios. Este documento apresenta as questões de pesquisa, hipóteses, protocolo de coleta e a amostra congelada de 300 repositórios. Três avaliações declaradas humanas e independentes cobrem 60 projetos e 300 releases. A heurística revisada atinge F1 de pelo menos 0,70 nessa amostra. Os tipos cobrem os 300 repositórios: os 240 restantes passaram por revisão individual após pré-classificação automática. RQ05 e RQ06 são analisadas com testes de postos, correção de multiplicidade, intervalos bootstrap, permutação e análise de influência.*

1. Introdução

As métricas DORA (*DevOps Research and Assessment*) tornaram-se o padrão de mercado para medir o desempenho de entrega de software [Forsgren et al. 2018, DORA sd]. Quatro métricas descrevem duas dimensões: velocidade, com a frequência de implantação (*deployment frequency*) e o tempo de entrega de mudanças (*lead time for changes*); e estabilidade, com a taxa de falha das mudanças (*change failure rate*, CFR) e o tempo de recuperação.

Medir essas métricas em projetos *open-source* esbarra em um problema de construto: o GitHub não registra implantações em produção nem falhas em produção. O que existe são *releases*, *commits* e execuções de *workflows* de integração contínua. Neste trabalho, esses artefatos funcionam como *proxies*: uma *release* publicada representa uma implantação, e uma execução de CI que falhou representa uma falha. Um *proxy* pode

enganar. Uma biblioteca que publica uma *release* por mês não implanta nada em produção, pois quem faz isso são os seus usuários, e uma falha de pipeline não é uma falha em produção.

O objetivo deste estudo é minerar automaticamente as métricas DORA em repositórios populares do GitHub que usam GitHub Actions e avaliar quanto se pode confiar nessas medidas. Para isso, o grupo (i) calcula as métricas com definições operacionais explícitas, (ii) valida os critérios automáticos contra o julgamento humano e (iii) mede o quanto as conclusões mudam quando a definição da métrica muda. Este artigo responde às seguintes questões de pesquisa (RQ):

- **RQ01:** qual a frequência de *deploys* dos repositórios populares que usam CI/CD?
- **RQ02:** qual o tempo entre um *commit* e o seu respectivo *deploy*?
- **RQ03:** qual a taxa de falha das mudanças entregues por esses repositórios?
- **RQ04:** qual o tempo de recuperação após uma execução de CI/CD com falha?
- **RQ05:** repositórios com maior frequência de *deploy* apresentam maior ou menor taxa de falha?
- **RQ06:** quais características dos repositórios estão associadas a um melhor desempenho DORA?
- **RQ07:** o quanto a classificação DORA de um repositório depende da definição operacional escolhida?

1.1. Hipóteses

As hipóteses abaixo foram escritas antes de qualquer análise dos dados coletados.

- **H1 (RQ01).** Esperamos que a mediana fique abaixo de uma *release* por semana, pois a maioria dos projetos populares são bibliotecas e ferramentas que publicam versões por ciclos de funcionalidades, e não de forma contínua. Esperamos também uma cauda longa, com poucos repositórios publicando *releases* diariamente.
- **H2 (RQ02).** Esperamos que o *lead time* por *release* (variante a) seja bem maior que o por *commit* (variante b), porque a variante (a) é dominada pelo *commit* mais antigo de cada *release*, enquanto a (b) pondera todos os *commits*, a maioria deles escrita perto da publicação.
- **H3 (RQ03).** Esperamos que o CFR de pipeline (variante a) seja maior que o CFR de entrega (variante b), pois falhas de CI são baratas, frequentes e ocorrem justamente para impedir que o problema chegue a uma *release*, enquanto *releases* corretivas em até sete dias são mais raras.
- **H4 (RQ04).** Esperamos que a mediana do tempo de recuperação seja de poucas horas, já que falhas de CI costumam ser corrigidas por um novo *commit* no mesmo dia, mas com cauda pesada e uma proporção não desprezível de episódios censurados, de *workflows* quebrados que ficam abandonados por semanas.
- **H5 (RQ05).** Esperamos uma correlação fraca e negativa entre a frequência de *deploys* e o CFR, isto é, que repositórios que entregam com maior frequência tenham taxa de falha igual ou menor. Essa expectativa acompanha a evidência do DORA de que velocidade e estabilidade não constituem necessariamente um *trade-off* [DORA 2026]. Entretanto, a associação pode ser mais fraca nos nossos proxies, já que falhas de CI não representam necessariamente falhas das versões entregues, e correlação não demonstra causalidade.

- **H6 (RQ06).** Esperamos que o tipo do projeto e o tamanho da comunidade de contribuidores apresentem associações mais claras com o desempenho DORA do que a linguagem principal. Aplicações e serviços devem publicar com maior frequência, enquanto comunidades maiores podem sustentar revisão, manutenção e recuperação mais contínuas. Popularidade, idade e linguagem podem apresentar associações menos uniformes; elas serão interpretadas sem atribuição de efeito causal.
- **H7 (RQ07).** Esperamos concordância moderada ou alta entre as classificações, mas com mudanças nos repositórios próximos aos limites das categorias. Incluir pré-releases ou tags pode aumentar a frequência medida; trocar o *lead time* por release pelo *lead time* por commit altera a ponderação; e substituir falhas de CI por releases corretivas observa outro tipo de falha. Essa sensibilidade reforça a necessidade de explicitar os proxies usados.

2. Metodologia

2.1. Desenho e população

O estudo é observacional e utiliza dados públicos do GitHub. A janela oficial é de 1 de outubro de 2025 a 30 de setembro de 2026. A amostra completa deve conter pelo menos 300 repositórios não arquivados e não derivados de forks, com GitHub Actions, no mínimo cinco releases principais e 50 execuções válidas de CI na janela. Os candidatos são embaralhados com semente 42 e avaliados em ordem até atingir a meta. O funil diferencia a população retornada pela busca dos candidatos efetivamente avaliados. O snapshot reutilizado mantém as consultas de origem; faixas adicionais previstas no config não são apresentadas como consultas que já ocorreram.

Foram retornados 53.143 candidatos e avaliados 2.644, chegando a 300 repositórios. As consultas do snapshot abrangem 1.000 a 8.000 estrelas.

Tabela 1. Funil de seleção dos repositórios.

Etapa	Entraram	Descartados	Restaram
Candidatos retornados pela busca	53.143	–	53.143
Candidatos avaliados (ordem aleatória)	2.644	–	2.644
Usam GitHub Actions	2.644	1.149	1.495
$\geq$ 5 releases publicadas na janela	1.495	1.082	413
$\geq$ 50 execuções de CI válidas	413	113	300
Amostra final	–	–	300

2.2. Definições operacionais

CI corresponde às execuções disparadas por `push` no default branch. Sucesso é a conclusão `success`; falha inclui `failure`, `timed_out` e `startup_failure`. Os demais estados são ignorados e contabilizados separadamente. Releases não draft e não pré-release, publicadas na janela, representam entregas; essa aproximação não comprova implantação em produção.

A frequência de entrega é o número de releases principais dividido pela duração inclusiva da janela em semanas. As variantes incluem pré-releases ou utilizam tags, cuja

data é a autoria do commit apontado, e não uma data de criação da tag. O lead time utiliza `commit.author.date`: na variante (a), calcula-se a mediana do maior tempo de cada release; na variante (b), a mediana das relações release/commit válidas. Ambas são expressas em horas. Commits inválidos, comparações indisponíveis e releases sem commits não são convertidos em tempos iguais a zero.

O CFR (a) é a quantidade de runs com falha dividida por falhas mais sucessos. O CFR (b) identifica uma release com falha quando outra release corretiva é publicada posteriormente, em até sete dias, inclusive. As sete últimas datas da janela ficam fora do denominador por censura à direita. O tempo de recuperação é medido por workflow, do início da primeira falha após um sucesso ao término do próximo sucesso; falhas consecutivas pertencem ao mesmo episódio. Episódios sem sucesso posterior permanecem censurados, e falhas iniciais sem sucesso anterior não abrem um episódio observável.

2.3. Amostra-ouro e validação da heurística

O sorteio canônico usa `validacao.amostra_ouro`: a população é ordenada por nome antes de selecionar 60 repositórios com semente 42; as releases principais de cada repositório são ordenadas por identificador antes de selecionar cinco, também com semente 42. A população de origem é a amostra completa congelada, não o piloto de 100 repositórios. As três planilhas têm os mesmos identificadores e links, sem previsões da heurística.

O protocolo prevê três avaliações independentes do tipo do projeto, da existência de entregas reais e do objetivo corretivo de cada release. Biblioteca/framework, aplicação/serviço, ferramenta CLI e outro são as categorias de tipo. Correção de defeito recente, regressão, vulnerabilidade ou reversão defeituosa deve ser o objetivo principal de uma release corretiva; versões mistas sem esse foco são negativas. Os manifestos registram a declaração de independência e a integridade de cada arquivo; hashes não comprovam, por si só, independência cognitiva.

A concordância é calculada pelo kappa de Fleiss, com interpretação descritiva de Landis–Koch [Landis and Koch 1977]. O consenso usa unanimidade ou maioria simples; os casos 1–1–1 exigem decisão adicional identificada e justificada, sem declarar uma reunião que não ocorreu. A origem, os hashes e a cobertura dos rótulos devem corresponder à amostra-ouro antes de incorporar o consenso ao dataset.

A heurística v1 combina patch SemVer crescente, mantendo major/minor, com a presença dos tokens completos `fix`, `hotfix` ou `revert` nos commits. Tags não-SemVer usam apenas o critério textual. Precisão, recall e F1 são calculados contra o consenso da amostra definitiva. Cada regra avaliada fica registrada, inclusive quando não atinge F1 de 0,70. Resultados obtidos sobre a amostra piloto não certificam automaticamente a nova população.

A v1 foi avaliada como baseline, seguida pela v2 de refinamento e pela v3 de correção técnica. A v3 preserva a filtragem da v2: analisa o título do commit e desconsidera prefixos de manutenção, documentação, CI, build, testes e refatoração, além de termos de rotina como atualização de dependências. Reconhece os termos de correção configurados e indícios explícitos de defeito, como vulnerabilidade, regressão e crash. Cada commit contribui no máximo uma vez para a contagem corretiva, mesmo que contenha vários termos. Com funcionalidades presentes, exige no mínimo três commits corretivos e razão

de pelo menos 2,5 por commit de funcionalidade. Sem funcionalidades, basta um commit corretivo elegível.

O parser aceita os prefixos de tags usados pela v2. Com análise textual ligada, um incremento patch sozinho não comprova correção: precisa de evidência textual e ausência de funcionalidades para acionar o critério patch. Se a análise textual for explicitamente desligada, mensagens não são consultadas e o critério patch pode operar isoladamente, se habilitado. A configuração principal mantém ambos os controles ligados. A v3 corrige a contagem múltipla por termos e a dependência textual que persistia com o controle desligado na v2; versões e resultados anteriores permanecem registrados, sem reescrever os votos de referência.

Os três manifestos definitivos registram avaliações humanas declaradas pelos integrantes, com identificadores individuais e hashes dos arquivos e itens. Não houve empate 1–1–1 na amostra, portanto não foi necessária reunião de desempate. O refinamento e a avaliação da heurística usaram a amostra-ouro de 60 repositórios. Para os 240 projetos restantes, um script produziu sugestões de categoria e justificativa a partir de descrições, tópicos e regras por projeto, com links para os READMEs. Segundo confirmação dos integrantes, cada um revisou individualmente seu lote de 80 projetos, consultando os READMEs e confirmando as categorias e justificativas antes da consolidação do manifesto. A revisão complementar foi realizada em 15 de outubro de 2026 e cobre somente o tipo do projeto, não novas avaliações de releases. Seus rótulos e proveniência são separados do consenso triplo dos 60, alcançando a cobertura de tipos dos 300 projetos.

A rotulagem da amostra definitiva é humana, com três avaliações de 60 projetos e 300 releases. A heurística v3 obteve precisão 0.708, recall 0.782 e F1 0.743; VP=68, FP=28, FN=19 e VN=185.

Tabela 2. Concordância entre os três avaliadores (kappa de Fleiss).

Dimensão	n	Unânime (%)	κ	Interpretação
Tipo do projeto	60	96,7	0,97	quase perfeita
Releases são entregas reais	60	100,0	1,00	quase perfeita
Release corretiva	300	97,7	0,96	quase perfeita

2.4. Ameaças à validade e reprodução

Releases, workflows e recuperação de CI são proxies e podem divergir de entregas e incidentes em produção. Notas incompletas, tags móveis, versões paralelas de monorepositórios e ambiguidades de classificação limitam a interpretação. A censura e as informações ausentes são quantificadas, não substituídas por zeros. Refinar e avaliar uma heurística na mesma amostra pode superestimar sua generalização; o limiar de F1 não constitui evidência de desempenho em dados não vistos. Divergências e subjetividades de classificação humana constituem limites inerentes ao processo qualitativo, sendo quantificadas pelo cálculo de concordância na amostra-ouro. Nos 240 tipos complementares houve uma revisão humana por projeto, não três; as sugestões automáticas podem induzir viés de confirmação. Os READMEs consultados na data da revisão também podem diferir do conteúdo existente durante a janela de coleta.

Código, testes, dados e manifestos para reprodução:

https://github.com/PedroMaiaAlves/lab-experimentacao-software

2.5. Coleta completa e consolidação do dataset

A coleta da Sprint 2 utiliza a janela de 1 de outubro de 2025 a 30 de setembro de 2026, semente 42 e meta mínima de 300 repositórios após os filtros de inclusão. O comando de coleta permite reaproveitar um snapshot versionado de candidatos; nesse caso, sua ordem e consultas de origem são preservadas. Uma nova busca pode ampliar as faixas de estrelas, com subdivisão para respeitar o teto da Search API. Não se considera a amostra final congelada antes da coleta e validação completas.

O pipeline utiliza Python e `requests`, sem bibliotecas que encapsulem a API do GitHub. São consultados os endpoints de workflows, releases, comparações entre tags, commits, contribuidores e execuções do GitHub Actions. As tags podem ser recuperadas em lotes por GraphQL. Releases e comparações são paginadas; a data de autoria do commit é utilizada nos cálculos de lead time e nas datas das tags. Os runs são restritos ao default branch, ao evento push e à janela do estudo. Consultas mensais com pelo menos mil resultados são subdivididas; intervalos diários ainda saturados são registrados como incompletos e impedem o congelamento.

O cache em disco permite reutilizar respostas, enquanto checkpoints registram o avanço da seleção e as coletas completas por repositório. O cliente respeita os limites indicados nos cabeçalhos e aplica novas tentativas com espera crescente em falhas temporárias. Erros transitórios não constituem evidência de exclusão. Comparações com erro 404 são contabilizadas e excluídas do lead time; datas inválidas de commits também são registradas e excluídas das medianas.

A execução completa terminou em 15 de outubro de 2026, às 05:15 UTC. O ambiente de execução utilizou Python 3.12.14. A instrumentação parcial, iniciada após o começo da coleta, registrou 25.634 respostas HTTP (25.624 com status 200 e dez com status 404) e três esperas, somando três segundos solicitados. Esses valores não incluem acertos de cache nem representam todas as requisições desde a seleção inicial. As esperas registradas não comprovam, isoladamente, ocorrência de rate limit. As 311 fontes congeladas são distribuídas em arquivo ZIP, com verificação SHA-256; a restauração e o recálculo sem acesso à API reproduziram exatamente o dataset.

O dataset reutiliza as funções de cálculo do grupo, mantém uma linha por repositório e registra métricas, versão da heurística e contagens de ignorados e censurados. O CFR de CI considera falhas sobre falhas mais sucessos. O CFR por release observa uma corretiva posterior em até sete dias, excluindo do denominador as releases das sete últimas datas da janela. Episódios de recuperação não encerrados são mantidos como censurados. Valores ausentes não são substituídos por zero. Tipos complementares só são incorporados com revisão declarada e proveniência separada do consenso. O consenso somente é incorporado quando seu manifesto confirma a origem da rotulagem e o vínculo, por hashes, com a amostra congelada. O consenso legado do piloto sem esse vínculo não é considerado validação da nova coleta. A avaliação definitiva da amostra-ouro utiliza as três planilhas com origem humana declarada pelos integrantes, rigorosamente vinculadas à população congelada. O consenso fornece o tipo e a validação para os 60 projetos sorteados, e a classificação complementar dos outros 240 projetos foi revisada pelos integrantes após sugestões automáticas e integrada com proveniência e links de evidência,

totalizando os 300 projetos com tipo. O importador verifica cobertura exata, categorias, campos obrigatórios, formato das URLs e datas, hashes e metadados do manifesto. Ele não comprova automaticamente a realização da revisão humana ou a disponibilidade das páginas externas. Arquivos já atestados não são sobrescritos durante a conferência.

A execução concluída reuniu 300 repositórios, na janela de 2025-10-01 a 2026-09-30. Foram contabilizados 11453 releases principais, 291405 runs válidos e 22871 runs ignorados. Houve 9 comparações com erro 404 e 561 relações release/commit com data inválida. No CFR (b), 274 releases foram censuradas. Dos 7861 episódios de falha, 90 permaneceram censurados. Foram registrados 56 intervalos saturados (incluindo subdivisões), com 0 incompletos. Todos os 300 repositórios possuem classificação de tipo de projeto atribuída (60 pela amostra-ouro com consenso triplo e 240 por avaliação complementar documentada). O CFR (b) ficou indisponível em 11 repositórios por evidência textual insuficiente.

3. Resultados e discussão: RQ05 e RQ06

As análises utilizam uma observação por repositório, sem ponderação por número de commits ou runs. Os 11 CFR(b) indisponíveis e os 22 tempos de recuperação ausentes não são imputados: os denominadores são 300, 289 ou 278, conforme a métrica. Nos 22 casos não houve episódio observável, o que não significa recuperação instantânea. Os 90 episódios censurados, dentre 7.861, permanecem registrados; as medianas de recuperação utilizam apenas episódios concluídos.

3.1. RQ05: frequência e falhas

Calculamos Spearman bilateral para cada proxy. Como diferencial, estimamos intervalos de confiança de 95% por bootstrap BCa pareado e p-valores por permutação dos pareamentos, ambos com 9.999 reamostragens e semente 42. A recomendação de conferir o p-valor assintótico em amostras menores está na documentação do SciPy [SciPy Community 2026b, SciPy Community 2026a]. Holm corrige a família dos dois p-valores de permutação, mantendo os p-valores originais de Spearman.

Tabela 3. RQ05: associações e incerteza. Última coluna: permutação após Holm.

Proxy	n	ρ [IC 95%]	p Spearman	p perm./Holm
CFR (a)	300	0,015 [-0,095; 0,125]	0,7993	0,8096
CFR (b)	289	0,660 [0,585; 0,724]	$1,48 \times 10^{-37}$	0,0004

O CFR de CI apresenta associação próxima de zero ($\rho = 0{,}015$), com IC que inclui zero. Para o CFR de entrega, a associação é positiva ($\rho = 0{,}660$), com IC de 0,585 a 0,724. A Figura 1 preserva os CFR iguais a zero; apenas a frequência usa escala logarítmica. O p-valor por permutação tem resolução finita, portanto seu valor pequeno não é apresentado como zero.

Retirar um projeto por vez mantém o sinal das duas correlações. O ρ de CI varia entre 0,006 e 0,024; o de entrega, entre 0,657 e 0,668. As maiores alterações absolutas são 0,0093 e 0,0076, respectivamente. A associação positiva de entrega não depende de um único repositório; isso não resolve vieses compartilhados pela amostra ou pela definição operacional.

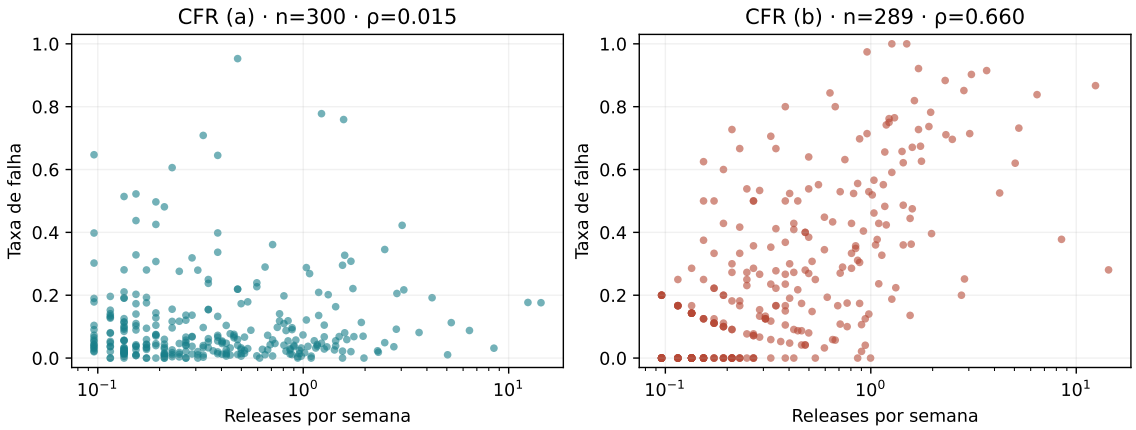


Figura 1. Frequência de releases e os dois proxies de falha. Cada ponto é um projeto.

H5 não é sustentada: esperava-se associação fraca e negativa. Não encontramos evidência de associação monotônica no proxy de CI, enquanto o de entrega associa maior frequência a maior CFR. Esse resultado não contradiz diretamente a evidência DORA sobre produção: nossos eventos são proxies. Uma explicação metodológica possível é que publicar mais releases cria mais oportunidades de encontrar uma corretiva nos sete dias seguintes. A associação pode refletir esse acoplamento, além de diferenças reais entre projetos; o estudo não identifica a contribuição causal de cada mecanismo.

3.2. RQ06: tipo, comunidade e linguagem

Escolhemos os três fatores ligados à H6. Os quartis de contribuidores têm limites 1, 23, 55,5, 125,5 e 1.963, preservando empates: os grupos possuem 76, 74, 75 e 75 projetos. Linguagens com menos de dez projetos formam "Outras" (67 projetos), resultando em nove grupos. Os quatro tipos originais são mantidos. Grupos são fixados antes das exclusões por métrica.

Aplicamos Kruskal–Wallis às 18 combinações dos três fatores com frequência, lead time (a)/(b), CFR (a)/(b) e recuperação. O código também contempla dois grupos com Mann–Whitney e Cliff's δ; esse caso não ocorre na amostra. Reportamos $\varepsilon^2 = H/(n-1)$ e corrigimos conjuntamente os 18 p-valores por Holm ($\alpha = 0{,}05$). Mediana, Q1, Q3, IQR, tamanhos dos grupos, ausências e os 18 resultados completos estão nos CSVs reproduzíveis.

Tabela 4. RQ06: seis comparações com p ajustado menor que 0,05, de 18 realizadas.

Fator	Métrica	n	p Holm	ε^2 / δ
Tipo do projeto	Recuperação	278	0,0347	0,051
Contribuidores (quartis)	Lead time (a)	300	$8{,}10 \times 10^{-7}$	0,124
Contribuidores (quartis)	Lead time (b)	300	$6{,}11 \times 10^{-9}$	0,157
Contribuidores (quartis)	Recuperação	278	0,0092	0,062
Linguagem	Lead time (a)	300	0,0002	0,124
Linguagem	Lead time (b)	300	0,0199	0,084

A comunidade de contribuidores se associa aos dois lead times e à recuperação; a linguagem, aos dois lead times; e o tipo, à recuperação. Não encontramos evidência

ajustada de diferenças em frequência ou CFR por esses fatores. A magnitude dos efeitos observados consta na Figura 2; significância não equivale a relevância prática, e grupos de composições distintas não permitem um ranking causal dos fatores.

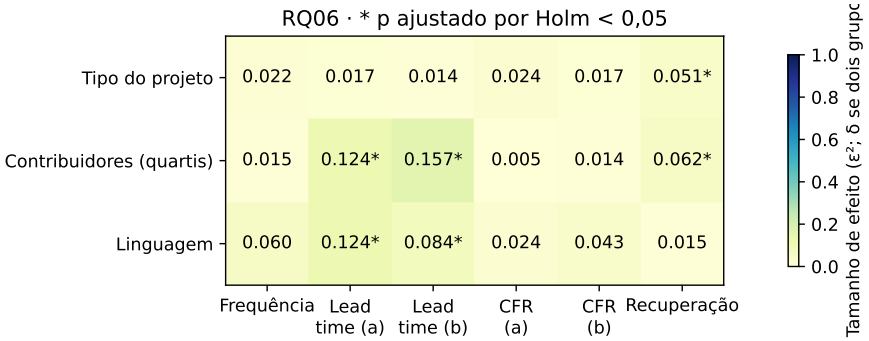


Figura 2. RQ06: tamanho de efeito nas 18 comparações; asteriscos indicam Holm $< 0{,}05$.

H6 recebe apoio parcial. Contribuidores apresentam associações, mas comunidades maiores não exibem os tempos menores esperados: o lead time (b) mediano passa de 53,95 horas no Q1 (Q1–Q3: 20,24–196,94) a 421,34 horas no Q4 (170,68–1.285,34). A recuperação mediana é 0,70 hora no primeiro quartil (0,39–6,71) e 4,62 horas no último (2,07–20,94). A linguagem também apresenta associações, e o tipo não distingue a frequência após o ajuste. Esses contrastes são descritivos: o teste global não identifica quais pares diferem, e não foram realizados testes post-hoc. Complexidade, idade e políticas de publicação podem confundir essas relações.

3.3. Limites das conclusões desta etapa

Bootstrap, permutação e análise de influência quantificam estabilidade condicionada à amostra, sem corrigir seleção, ausência potencialmente informativa ou erros da heurística. O grupo "outro" possui apenas seis recuperações observadas. O tipo provém de consenso triplo em 60 projetos e revisão individual após sugestões automáticas em 240. A amostra cobre projetos com 1.000 a 8.000 estrelas, e a heurística foi refinada e avaliada na mesma amostra-ouro. Essas limitações impedem generalização automática para produção ou para todo o GitHub. A análise de sensibilidade da RQ07 será necessária para avaliar mudanças de definição operacional; a estabilidade individual aqui medida não a substitui.

Referências

DORA (2026). DORA's software delivery performance metrics. `https://dora.dev/guides/dora-metrics/`. Acesso em: 7 out. 2026.

DORA (s.d.). Accelerate state of DevOps reports. `https://dora.dev/research/`. Acesso em: out. 2026.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

SciPy Community (2026a). scipy.stats.bootstrap. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.bootstrap.html. Acesso em 18 de outubro de 2026.

SciPy Community (2026b). scipy.stats.spearmanr. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html. Acesso em 18 de outubro de 2026.