

RELATÓRIO DE LABORATÓRIO

Mineração e análise dos 1.000 repositórios mais populares do GitHub

Lab01 — Relatório Final

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Professor	Danilo Maia
Entrega	Lab01 — entrega final
Integrantes	Pedro Henrique Maia Alves; Diogo C. Brunoro; Lorrان Pedro Avelar Xavier
Repositório	https://github.com/PedroMaiaAlves/lab-experimentacao-software
GitHub Project	https://github.com/users/PedroMaiaAlves/projects/1
Data de geração	26/08/2026

Belo Horizonte
2026

1. Introdução

O GitHub reúne projetos com diferentes níveis de maturidade, atividade e participação. Este laboratório investiga características dos 1.000 repositórios públicos mais estrelados retornados pela API GraphQL. Estrelas são usadas como definição operacional de popularidade, sem pressupor qualidade técnica.

Este relatório consolida as sete questões de pesquisa exigidas pelo enunciado (RQ01–RQ07) e, como extensão do grupo, as RQ08 (popularidade e intensidade anual), RQ09 (colaboração e releases) e RQ10 (maturidade e issues). A aplicação Streamlit integra mineração, análise, visualização e exportação do CSV.

As hipóteses são informais e exploratórias: orientam a leitura descritiva, não foram pré-registradas e não substituem testes confirmatórios.

1.1 Questões de pesquisa e hipóteses informais

RQ	Pergunta	Hipótese informal
RQ01	Sistemas populares são maduros/antigos?	H01: a idade mediana é superior a cinco anos.
RQ02	Sistemas populares recebem muita contribuição externa?	H02: a mediana supera 500 PRs mescladas e a distribuição é assimétrica.
RQ03	Sistemas populares lançam releases com frequência?	H03: a maioria possui releases e a mediana acumulada supera 20.
RQ04	Sistemas populares são atualizados com frequência?	H04: a maioria recebeu push nos últimos 30 dias.
RQ05	Sistemas populares usam linguagens populares?	H05: mais da metade usa uma linguagem do Top 10 Octoverse 2025.
RQ06	Sistemas populares possuem alto percentual de issues fechadas?	H06: a mediana de fechamento supera 80% entre projetos com issues.
RQ07	Linguagens populares recebem mais contribuição, releases e atualização?	H07: o grupo Top 10 tem maiores medianas de PRs e releases e menor recência.
RQ08	Popularidade está associada à intensidade anual de desenvolvimento?	H08: estrelas apresentam associação positiva ao menos moderada com PRs/ano e releases/ano.
RQ09	Maior intensidade de PRs está associada a maior intensidade de releases?	H09: espera-se associação positiva entre PRs mescladas/ano e releases/ano.
RQ10	Repositórios mais antigos apresentam maior proporção de issues fechadas?	H10: repositórios mais antigos apresentam maior percentual mediano de issues fechadas, por possuírem processos de manutenção mais consolidados.

2. Desenvolvimento

2.1 Evolução do trabalho em S01, S02 e S03

Na S01 foram implementadas a consulta GraphQL inicial, a transformação tabular, as RQ01–RQ07 e a primeira interface Streamlit. Na S02, o coletor em lote passou a percorrer cursores até reunir exatamente 1.000 nomes únicos, exportar CSV e registrar o primeiro snapshot do Project.

Na S03, a Issue #44 incorporou a RQ08 com taxas anualizadas, correlações, quartis e visualizações. A Issue #45 acrescentou a RQ09, relacionando PRs mescladas/ano e releases/ano. A Issue #46 incorporou a RQ10 sobre idade e percentual de issues fechadas, e a Issue #47 evoluiu a exibição e a busca no Streamlit.

Sprint	Atividade	Responsável	Rastreabilidade
S01	Coleta inicial, RQ01–RQ07 e Streamlit	Pedro e Diogo	Issues e PRs da S01
S02	Paginação para 1.000, CSV, validação e hipóteses	Pedro e Diogo	Issues #8–#15 e #22–#38
S03	RQ08 — popularidade e intensidade	Pedro Henrique Maia Alves	Issue #44
S03	RQ09 — colaboração e releases	Lorran Pedro Avelar Xavier	Issue #45
S03	RQ10 — maturidade e issues	Diogo	Issue #46 — concluída
S03	Evolução de exibição e busca	Diogo	Issue #47 — concluída

2.2 Arquitetura e fluxo implementado

- `main.py` pagina a consulta GraphQL, valida avanço dos cursores e encerra apenas com 1.000 repositórios únicos;
- `utils/dataframe.py` converte o snapshot bruto e calcula métricas derivadas reproduzíveis;
- `analysis` contém módulos independentes de RQ01 a RQ10 e exporta dez JSONs estritos;
- `app.py` apresenta abas para RQ01–RQ10, busca por repositório e download do CSV com as taxas e correlações anualizadas;
- `gerar_relatorio_docx.py` recalcula todos os números exibidos a partir do mesmo CSV canônico.

2.3 Inovação: aplicação Streamlit

A inovação do grupo é uma aplicação interativa em Streamlit. A versão atual apresenta a RQ08 com coeficientes, quartis, sensibilidade e gráficos de dispersão, a RQ09 com correlação, quartis de PRs, tendência e identificação de outliers, além da RQ10 com a relação entre idade e fechamento de issues. Os tooltips preservam os valores originais e as taxas anualizadas usam `symlog`, mantendo observações iguais a zero.

A evolução da Issue #47 acrescentou busca e filtragem por repositório às visualizações. A mineração em lote permanece centralizada no `main.py`, enquanto o Streamlit atua como camada de exploração e comunicação dos resultados.

3. Metodologia

3.1 Seleção e paginação

A população operacional corresponde aos repositórios públicos encontrados por `stars:>0 is:public sort:stars-desc`. A conexão `search` é percorrida em lotes de até 50. Cada nova chamada recebe em `after` o `endCursor` anterior; `hasNextPage`, `cursor` ausente ou repetido e página vazia são verificados. Duplicatas por `nameWithOwner` são descartadas até atingir exatamente 1.000 projetos.

3.2 Transformação e métricas

RQ	Métrica operacional
RQ01	(data da transformação – <code>createdAt</code>) / 365,25, em anos
RQ02	<code>pullRequests(states: MERGED).totalCount</code> ; não identifica autoria externa
RQ03	<code>releases.totalCount</code> acumulado
RQ04	dias entre a transformação e <code>pushedAt</code>
RQ05	<code>primaryLanguage</code> comparada ao Top 10 Octoverse 2025
RQ06	$100 \times \text{issues fechadas} / (\text{abertas} + \text{fechadas})$
RQ07	medianas de PRs, releases e recência por grupo de linguagem
RQ08	PRs/ano e releases/ano, divididos pela idade registrada no CSV
RQ09	Spearman entre PRs mescladas/ano e releases/ano; medianas por quartil de PRs
RQ10	idade $\times$ percentual de issues fechadas; Spearman e mediana/Q1/Q3/IQR por faixa etária

A idade é arredondada para duas casas antes da anualização; as duas taxas são arredondadas para quatro casas. Idades não positivas produzem valor nulo, sem resultados numéricos inválidos.

3.3 Procedimento analítico da RQ08

A análise principal inclui idade ≥ 1 ano ($n = 917$); a sensibilidade inclui toda idade positiva ($n = 1000$). Spearman é calculado como Pearson entre postos médios, sem SciPy. Os quartis são formados após ordenação estável por estrelas e nome. Outliers seguem $1,5 \times \text{IQR}$ e permanecem em todas as análises.

A anualização reduz o efeito mecânico do tempo de existência, mas não controla domínio, tamanho da equipe, governança, automação ou trajetória histórica. As associações não permitem inferência causal.

3.4 Procedimento analítico da RQ09

A RQ09 usa os 917 repositórios com idade ≥ 1 ano. PRs mescladas e releases acumuladas são divididas pela idade registrada no CSV, com quatro casas decimais. Spearman é calculado entre as duas taxas usando postos médios; os quartis são formados após ordenação estável por PRs/ano e nome.

Outliers são identificados separadamente nas duas taxas pelo critério de $1,5 \times \text{IQR}$ e mantidos na correlação e nos quartis. A linha de tendência é uma regressão linear descritiva sobre as taxas anualizadas e não substitui a associação monotônica de Spearman.

3.5 Procedimento analítico da RQ10

A RQ10 utiliza a idade registrada no CSV e o percentual acumulado de issues fechadas. Dos 1.000 projetos, 957 possuem ao menos uma issue e formam a amostra válida; os 43 sem issues têm percentual estruturalmente indefinido e são excluídos da correlação e dos resumos por faixa.

A associação monotônica é estimada por Spearman, calculado como a correlação de Pearson entre postos médios para tratar empates. A distribuição é resumida nas faixas 0–2, >2–5, >5–10, >10–15 e >15 anos, usando quantidade, mediana, primeiro quartil, terceiro quartil e IQR. Outliers seguem $1,5 \times \text{IQR}$ e são mantidos na análise.

O percentual acumulado de fechamento não mede velocidade, complexidade ou qualidade da resolução. Projetos podem usar rastreadores externos, e a análise transversal não permite atribuir diferenças etárias a processos de manutenção mais consolidados.

4. Resultados

4.1 Validação do snapshot

O snapshot contém 1.000 linhas, 1.000 nomes e 1.000 URLs únicas. As estrelas estão em ordem não crescente. O CSV contém as taxas PRs por ano e Releases por ano, e os dez arquivos JSON de RQ01–RQ10 registram `total_repositorios` = 1.000.

4.2 Visualizações e resultados por RQ

4.2.1 RQ01 — Sistemas populares são maduros/antigos?

A idade mediana foi 7,71 anos e a média 7,64. O intervalo observado foi de 0,03 a 18,37 anos. As faixas <2, 2–<5, 5–<10 e ≥ 10 anos reuniram, respectivamente, 141, 185, 331, 343 projetos.




Figura 2 — Distribuição da idade dos repositórios.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.2 RQ02 — Sistemas populares recebem muita contribuição externa?

A mediana foi 768 PRs mescladas, a média 4.255,21, Q1 174,00, Q3 3.409,00 e o máximo 103.641. Há 20 projetos com zero e 124 outliers superiores.

Repositório	PRs mescladas
firstcontributions/first-contributions	103.641
llvm/llvm-project	98.120
elastic/elasticsearch	95.877

PRs mescladas aproximam volume de contribuição, mas a consulta não permite afirmar que a contribuição veio de pessoas externas ao projeto.




Figura 3 — Distribuição por faixa de pull requests mescladas.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.3 RQ03 — Sistemas populares lançam releases com frequência?

A mediana acumulada foi 42, a média 158,77, Q1 0,00, Q3 153,00 e o máximo 6.951. 728 projetos (72,8%) possuem ao menos uma release; 272 possuem zero. Foram detectados 92 outliers superiores.

Repositório	Releases
ggml-org/llama.cpp	6.951
gradio-app/gradio	5.095
vercel/next.js	3.823




Figura 4 — Distribuição por quantidade acumulada de releases.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.4 RQ04 — Sistemas populares são atualizados com frequência?

A mediana desde o último push foi 1,68 dias, a média 113,34 e o máximo 2.457,87. 728 projetos (72,8%) estavam em até 30 dias; 119 estavam há mais de um ano. O critério IQR identificou 198 outliers superiores.

Recência	Repositórios
Até 1 dia	436
>1 a 7 dias	177
>7 a 30 dias	115
>30 a 365 dias	153
>365 dias	119




Figura 5 — Distribuição do tempo desde o último push.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.5 RQ05 — Sistemas populares usam linguagens populares?

Foram observadas 43 linguagens definidas. O Top 10 Octoverse aparece em 703 projetos (70,3%) e em 77,0% daqueles com linguagem definida. 87 projetos não possuem linguagem primária definida.

Linguagem	Repositórios
Python	228
TypeScript	173
JavaScript	110
Não definida	87
Go	77
Rust	57
C++	42
Java	41




Figura 6 — Participação das linguagens do Top 10 GitHub Octoverse 2025.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.6 RQ06 — Sistemas populares possuem alto percentual de issues fechadas?

A taxa foi calculável em 957 projetos; 43 não possuíam issues. Entre os válidos, a mediana foi 87,60%, a média 80,35%, Q1 70,90%, Q3 96,80%, mínimo 7,50% e máximo 100,00%. 618 (64,6%) alcançaram pelo menos 80%.




Figura 7 — Distribuição do percentual de issues fechadas.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.7 RQ07 — Linguagens populares recebem mais contribuição, releases e atualizações?

A comparação exclui 87 projetos sem linguagem definida. As estatísticas abaixo foram recalculadas do CSV para os mesmos grupos do Octoverse.

Grupo	N	Mediana PRs	Mediana releases	Mediana dias
Top 10 Octoverse	703	1.000	64	1,14
Outras definidas	210	660	30	2,29




Figura 8 — Indicadores medianos por grupo de linguagens.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.8 RQ08 — Popularidade e intensidade anual de desenvolvimento

Na amostra principal (idade ≥ 1 ano; $n = 917$), estrelas $\times$ PRs/ano apresentou $p = 0,1534$ e estrelas $\times$ releases/ano $p = 0,0066$. Há 83 projetos com menos de um ano; nenhum outlier foi removido.

Quartil de estrelas	N	Limites de estrelas	Mediana PRs/ano	Mediana releases/ano
Q1	230	33.022–38.502	79,1039	5,3305
Q2	229	38.550–48.469	110,9813	7,4866
Q3	229	48.485–72.000	148,7047	7,1702
Q4	229	72.148–542.947	192,7794	4,8193

Na sensibilidade com todas as idades positivas ($n = 1000$), os coeficientes foram $p = 0,1451$ para PRs/ano e $p = 0,0070$ para releases/ano. O IQR marcou 112 extremos em PRs/ano, 92 em releases/ano e 165 na união.




Figura 9 — Dispersões de estrelas versus PRs/ano e releases/ano.


Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.9 RQ09 — Colaboração e publicação de releases

Na amostra principal (idade ≥ 1 ano; $n = 917$), a correlação entre PRs mescladas/ano e releases/ano foi positiva forte ($\rho = 0,6263$). As medianas de releases/ano cresceram em todos os quartis, de 0,0000 no Q1 para 27,4182 no Q4.

Faixa de PRs/ano	N	Limites de PRs/ano	Mediana PRs/ano	Mediana releases/ano
Q1 — menor intensidade	230	0,0000–26,1601	8,2430	0,0000
Q2	229	26,5625–115,5732	58,7389	3,1111
Q3	229	116,1959–554,4073	266,0714	11,7057
Q4 — maior intensidade	229	554,9703–10.831,1927	1.311,2195	27,4182

O critério de $1,5 \times \text{IQR}$ identificou 112 extremos em PRs/ano, 92 em releases/ano e 165 repositórios na união; 39 foram extremos nas duas taxas. Todos foram mantidos.

**Figura 10 — Dispersão de PRs/ano versus releases/ano, com outliers e linha de tendência.**

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.2.10 RQ10 — Maturidade e tratamento de issues

A análise inclui 957 repositórios com issues e exclui os 43 projetos sem issues. A correlação entre idade e percentual de issues fechadas foi positiva fraca ($\rho = 0,2323$). Entre os casos válidos, a idade mediana foi 7,65 anos e o percentual mediano de fechamento foi 87,60%.

As medianas por faixa cresceram em todas as transições, passando de 79,55% nos projetos de até dois anos para 95,40% naqueles com mais de quinze anos. Os intervalos interquartis, porém, apresentam sobreposição, e a última faixa contém apenas 43 projetos.

Faixa de idade	N	Mediana	Q1	Q3	IQR
0–2 anos	140	79,55%	57,28%	91,58%	34,30
>2–5 anos	176	84,95%	69,08%	95,22%	26,15
>5–10 anos	318	86,95%	67,72%	97,22%	29,50
>10–15 anos	280	91,85%	80,20%	97,60%	17,40
>15 anos	43	95,40%	88,55%	97,65%	9,10

No percentual de fechamento, o critério global de $1,5 \times \text{IQR}$ identificou 48 outliers inferiores e 0 superiores; todos foram mantidos. Há ainda 34 projetos no teto de 100% de issues fechadas.




Figura 11 — Relação entre idade e percentual de issues fechadas, com medianas e IQR por faixa etária.

Fonte: elaborado pelo grupo com dados da API GraphQL do GitHub, 2026.

4.3 Discussão e avaliação das hipóteses

4.3.1 RQ01

A mediana de 7,71 anos superou cinco anos. Projetos antigos tiveram mais tempo para acumular estrelas; o resultado não estabelece causalidade.

4.3.2 RQ02

A mediana de 768 superou 500. A diferença entre média e mediana e os 124 extremos mostram assimetria. A autoria externa não é identificável.

4.3.3 RQ03

72,8% possui release e a mediana é 42. O acumulado não mede intervalos nem frequência temporal.

4.3.4 RQ04

72,8% estava em até 30 dias. O último push mede recência, não frequência histórica, e pode refletir automação.

4.3.5 RQ05

O Top 10 representa 70,3% da amostra. O resultado depende do ranking temporal e primaryLanguage simplifica projetos multilíngues.

4.3.6 RQ06

A mediana de 87,60% descreve somente projetos com issues. A taxa não informa tempo, complexidade ou qualidade do fechamento.

4.3.7 RQ07

A comparação é descritiva. Diferenças entre grupos podem refletir idade, domínio, comunidade, governança e tamanhos desiguais, não o efeito da linguagem isoladamente.

4.3.8 RQ08

A relação com PRs/ano foi positiva fraca ($p = 0,1534$) e com releases/ano foi positiva desprezível ($p = 0,0066$). Assim, H08 não é sustentada no critério de duas associações positivas ao menos moderadas. A sensibilidade manteve a mesma interpretação geral.

4.3.9 RQ09

A H09 recebeu apoio descritivo: a associação foi positiva forte ($p = 0,6263$) e as medianas de releases/ano cresceram ao longo dos quartis de PRs/ano. O desenho transversal não demonstra que elevar a colaboração cause mais releases.

4.3.10 RQ10

A H10 recebeu apoio descritivo parcial. As medianas cresceram monotonicamente de 79,55% para 95,40%, mas a associação foi apenas positiva fraca ($p = 0,2323$) e os intervalos interquartis se sobrepõem. A idade isoladamente explica uma parcela limitada da variação e o desenho não permite inferir causalidade.

Hipótese	Avaliação exploratória
H01	Compatível
H02	Compatível descritivamente

Hipótese	Avaliação exploratória
H03	Compatível para presença/acumulado
H04	Compatível para recência
H05	Compatível
H06	Compatível entre projetos com issues
H07	Compatível descritivamente
H08	Não sustentada: as duas associações não foram ao menos moderadas
H09	Compatível descritivamente
H10	Parcialmente sustentada: tendência monotônica, mas associação fraca

4.3.11 Ameaças à validade

Validade de construto. Estrelas aproximam popularidade; PRs mescladas não garantem contribuição externa; releases acumuladas e último push não medem frequência histórica; linguagem primária não descreve todo o código. O percentual de issues fechadas é acumulado e não representa velocidade, dificuldade ou qualidade da resolução.

Anualização. Dividir acumulados pela idade supõe uma taxa média constante e amplifica valores de projetos muito jovens. Como PRs/ano e releases/ano usam a mesma idade como denominador, parte da associação pode refletir esse fator comum. Por isso, a análise principal exige ao menos um ano.

Ausências e efeito teto. Os 43 projetos sem issues podem usar rastreadores externos ou ainda não ter demandas registradas e foram excluídos da RQ10. Outros 34 aparecem no teto de 100%, reduzindo a discriminação entre projetos.

Outliers. Projetos com automação ou fluxos incomuns produzem taxas extremas. Eles foram identificados por $1,5 \times \text{IQR}$ e mantidos; a correlação por postos reduz, mas não elimina, sua influência interpretativa.

Arredondamento e agrupamento. Idades e percentuais registrados no CSV são arredondados, o que cria empates tratados por postos médios. As faixas etárias têm tamanhos distintos, e seus intervalos interquartis se sobrepõem.

Causalidade e confundimento. O estudo observacional não controla domínio, organização, tamanho da equipe, governança, efeitos de coorte ou sobrevivência. Associação entre estrelas, intensidade, idade e fechamento não demonstra causalidade.

Validade externa e temporal. A amostra cobre somente os 1.000 repositórios públicos mais estrelados no instante da coleta. Resultados não se generalizam automaticamente e podem variar entre snapshots.

5. Conclusão

A coleta oficial reuniu 1.000 repositórios únicos, ordenados por estrelas, e gerou CSV e dez JSONs coerentes para RQ01–RQ10. Todos os valores do relatório foram recalculados do mesmo snapshot, reduzindo o risco de divergência entre dados, texto, tabelas e gráficos.

RQ01–RQ07 descrevem maturidade, contribuições, releases, atualização, linguagens e issues. A RQ08 acrescenta controle simples por idade: na amostra principal, p foi 0,1534 para PRs/ano e 0,0066 para releases/ano. Os resultados não sustentam a hipótese de duas associações positivas ao menos moderadas e não autorizam conclusão causal.

A RQ09 respondeu positivamente à pergunta de pesquisa: PRs mescladas/ano e releases/ano apresentaram associação positiva forte ($p = 0,6263$), acompanhada pelo crescimento das medianas de releases/ano entre Q1 e Q4. A evidência é associativa e não causal.

Na RQ10, as medianas de issues fechadas aumentaram de 79,55% para 95,40% entre as faixas extremas, mas a correlação foi positiva fraca ($p = 0,2323$). A H10 recebeu apoio descritivo parcial, sem evidência de que a idade cause maior capacidade de fechamento.

O Streamlit comunica as RQ01–RQ10, oferece busca por repositório e download do CSV. As RQ08–RQ10 e a interface interativa são extensões do grupo além do mínimo exigido pelo enunciado.

6. Configuração do processo

O grupo utiliza GitHub Projects (v2) vinculado ao repositório do laboratório. Cada tarefa é registrada como Issue real, atribuída a um responsável e movimentada no board conforme o progresso efetivo do trio.

Elemento	Configuração adotada
Repositório	https://github.com/PedroMaiaAlves/lab-experimentacao-software
GitHub Project	https://github.com/users/PedroMaiaAlves/projects/1
Colunas (Status)	Backlog → To Do → Doing → Review → Done
Política de WIP (Doing)	2–3 tarefas por integrante por sprint (6–9 tarefas no total para o trio)
Rastreabilidade	Commits referenciam o número da Issue correspondente (#N)
Snapshots do board	Exportação manual em TSV/CSV em docs/snapshots/ (Issue #14 e fechamento do Lab01)

A política de WIP limita o trabalho simultâneo em Doing para preservar foco e revisão em trio. Com três integrantes, a faixa de 2–3 tarefas por pessoa resulta em sprints de 6–9 itens, equilibrando paralelismo e capacidade de code review antes de mover cartões para Done.

O fluxo do Lab01 no GitHub Project está registrado na Figura 12. Os snapshots em docs/snapshots/ serão base para os laboratórios 04 e 05, conforme orientação da disciplina.




Figura 12 — Fluxo do GitHub Project ao final do Lab01

Fonte: GitHub Projects — <https://github.com/users/PedroMaiaAlves/projects/1>. Captura de tela do grupo, 26 ago. 2026.

7. Referências

GITHUB. GraphQL API documentation. <https://docs.github.com/en/graphql>. Acesso em: 25 ago. 2026.

GITHUB. Using pagination in the GraphQL API. <https://docs.github.com/en/graphql/guides/using-pagination-in-the-graphql-api>. Acesso em: 25 ago. 2026.

GITHUB. Octoverse 2025. <https://github.blog/news-insights/octoverse/>. Acesso em: 25 ago. 2026.

KALLIAMVAKOU, E. et al. The promises and perils of mining GitHub. MSR, 2014. <https://doi.org/10.1145/2597073.2597074>.

PANDAS. Pandas documentation. <https://pandas.pydata.org/docs/>.

STREAMLIT. Streamlit documentation. <https://docs.streamlit.io/>.

VEGA-ALTAIR. Declarative visualization in Python. <https://altair-viz.github.io/>.